



Federated Full-Parameter Tuning of Billion-Sized Language Models with Communication Cost under 18 Kilobytes

Zhen Qin, Daoyuan Chen, Bingchen Qian, Bolin Ding, Yaliang Li*, Shuiguang Deng*
*Corresponding authors.

Zhejiang University, Alibaba Group

时间: 2024.7.21
会议: ICML

汇报人: 张豪杰

导师: 蔡惠

汇报时间: 2026.3.16


Federated Full-Parameter Tuning of Billion-Sized Language Models with Communication Cost under 18 Kilobytes



Yaliang Li

Alibaba Group, USA • Alibaba Group Holding Limited • Tencent • University of Illinois Urbana-Champaign
• University at Buffalo, The State University of New York

Bibliometrics	Average Citations per Article	Citation Count	Publication Count	Publication Years	Available for Download	Average Downloads per Article	Downloads (6 weeks)	Downloads (12 months)	Downloads (cumulative)
	35	4,087	117	2014 - 2025	90	1,230	2,858	27,683	110,743



Colleague Collaboration

Bolin Ding	51
Jing Gao	32
Daoyuan Chen	19
Jingren Zhou	19
Lu Su	17
Yuexiang Xie	17
Liuyi Yao	16
Wei Fan	14
Zhen Wang	13

[View all Colleagues](#) →



邓水光

博士

教授 | 博士生导师

单位 计算机科学与技术学院



电话 0571-87951647

邮箱 dengsg@zju.edu.cn

地址 玉泉校区则通楼305

研究方向 服务计算、云计算/边缘计算、类脑计算、软件工程、大数据

个人简介

新闻动态

教学与课程

发表论文

出版著作

学术兼职

奖励荣誉

实验室介绍

邓水光，浙江大学计算机科学与技术学院求是特聘教授，国家杰出青年基金获得者（2021年），IET Fellow，CCF杰出会员/CCF杰出演讲者。现担任浙江省数智服务技术重点实验室副主任、浙江大学数字农业农村研究中心副主任、浙江大学中原研究院大数据与人工智能研究中心主任、CCF服务计算专委会副主任。于2002、2007年毕业于浙江大学获计算机专业学士和博士学位；于2014年和2015年在美国麻省理工学院、斯坦福大学访问研究。曾获中国青年五四奖章、国家万人计划青年拔尖人才、IEEE TCSVC Rising Star、CCF服务计算杰出成就奖等荣誉称号。

主要研究方向为服务计算、云计算/边缘计算、类脑计算、软件工程、大数据等。担任IEEE Trans. on Services Computing (CCF A)、Knowledge and Information Systems (CCF B)等国际期刊Associate Editor。近年来，在国际权威期刊和会议上发表论文100余篇，获10次国际期刊和会议的杰出论文奖/最佳论文奖/最佳学生论文奖，入围2022-2024全球前2%顶尖科学家终身榜，入选爱思唯尔2020-2024年中国高被引学者；授权发明专利100余项（包括PCT国际发明专利授权6项），获得中国发明专利银奖1项、日内瓦国际专利展金奖1项、中国发明博览会金奖1项；在Springer、IET、Elsevier等出版5部学术专著；主持国家杰出青年基金项目、国家重点研发计划重点专项项目、国家自然科学基金基金区域联合重点项目、浙江省自然科学基金重大项目等，研究成果获国家科技进步二等奖1项，省部科技进步一等奖5项。

论文的背景和问题:

- 预训练的大型语言模型(LLMs)需要进行微调, **联邦学习(FL)**提供了一种提供了一种**不损害数据隐私**的前提下使用终端设备上丰富数据微调LLMs的方法;
- 现有的大多数LLMs的联邦微调方法依赖参数高效微调技术(PEFT), 但在**数据异构(Non-IID)场景下, PEFT的表现往往不如全参数微调**。而传统全参数微调通信成本和模型参数规模成正比, 大模型内存消耗极高, 无法适配终端设备。

论文的动机和贡献:

- **动机1:** 虽然全参数微调通常比PEFT效果更好, 但在联邦学习中, 传输数十亿参数(如LLaMA-3B)会导致每轮数GB的通信成本, 这对终端设备不可行;
- **动机2:** 传统的零阶优化(ZOO)方法存在通信成本高以及计算成本随轮数无限增加的难题;
- **贡献1:** 首个在联邦设备上实现十亿大小LLMs全参数调优FedKSeed框架, 仅在服务端和客户端之间传输K个种子和对应的标量梯度, 每轮通信成本不到18KB;
- **贡献2:** 研究了ZOO扰动差异化的重要性, 以非均匀概率对种子进行采样, 在提升准确率的同时, 减少了FedKSeed所需候选种子的数量, 加快了客户端与最新全局模型同步速度。




图1: 联邦零阶优化

表1: 联邦微调方法的准确率与客户端开销

Approach	Acc.↑	Commu.↓	Mem.↓	Comput.↓
PEFT with BP	★	$\mathcal{O}(\nu d)$	$\mathcal{O}(\xi d)$	$\mathcal{O}(d)$
Full-param. with BP	★★	$\mathcal{O}(d)$	$\mathcal{O}(\Xi d)$	$\mathcal{O}(d)$
Full-param. with ZOO	★★	$\mathcal{O}(d)$	$\mathcal{O}(d)$	$\mathcal{O}(d)$
infinite seed-pool in uplink	★★	$\mathcal{O}(d)$	$\mathcal{O}(d)$	$\mathcal{O}(d)$
infinite seed-pool in bi-link	★★	$\mathcal{O}(1)$	$\mathcal{O}(d)$	$\mathcal{O}(\tau rmd)$
FedKSeed ($ \text{seed-pool} =K$)	★★	$\mathcal{O}(1)$	$\mathcal{O}(d)$	$\mathcal{O}(d)$

大语言模型的联邦微调(Federated Fine-Tuning for LLMs):

由于LLMs参数规模极大(通常数十亿至上万亿), 若直接使用联邦学习(FL)进行“**全参数微调**”(Full-Parameter Tuning), 会**产生巨量通信成本**(传输全量模型参数)和**终端计算压力**(需要承载反向传播的显存消耗)。因此, PEFT——仅微调LLMs的少量关键参数, 在降低成本的同时保留模型适配能力, 成为联邦场景下的主流选择。

$$\min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w}) \triangleq \sum_{i=1}^N c_i \cdot \mathbb{E}_{\mathbf{x} \sim \mathcal{D}_i} [\mathcal{L}(\mathbf{w}; \mathbf{x})] \quad (1)$$

- $f(w)$: 全局损失函数;
- c_i : 客户端 i 的聚合权重, 用于平衡客户端的贡献;
- $\mathbf{x} \sim \mathcal{D}_i$: 从客户端 i 的私有数据集 $\mathcal{D}_i$ 中随机抽取一个数据样本 $\mathbf{x}$;
- $L(w; x)$: 模型参数为 w 时, 在样本 x 上的单样本损失;
- $\mathbb{E}_{\mathbf{x} \sim \mathcal{D}_i}[\cdot]$: 模型在 $\mathcal{D}_i$ 的平均损失。

➤ 联邦微调与传统联邦核心区别:

传统联邦学习从随机初始化的权重开始训练模型, 而联邦微调从预训练权重 w^0 开始优化——LLMs的与训练权重已经具备通用语言能力, **微调**只需要适配具体任务而**无需从头开始学习**。

联邦学习多**基于反向传播(BP)**计算梯度, 客户端的局部更新如下:

$$\mathbf{w}_{i,t+1}^r = \mathbf{w}_{i,t}^r - \eta \cdot \mathbf{g}_{i,t}^r \quad (2)$$

- $w_{i,t}^r$: 客户端 i 在第 r 轮联邦训练中, 第 t 步局部训练后的模型参数;
- η : 学习率;
- $g_{i,t}^r$: 客户端 i 在第 r 轮第 t 步的真实梯度。




图2: 大语言模型联邦微调

传统方法的局限:

- 基于BP的梯度计算需要存储大量中间计算结果(激活值、梯度), 内存消耗极高;
- 客户端与服务端之间的通信开销与训练参数量成正比, 训练参数量过大时(全参数微调)通信开销远超终端设备的通信能力。

零阶优化(Zeroth-Order Optimization, ZOO)[1]:

零阶优化(ZOO)是梯度难以获得的场景中的一项重要技术, 通过前向传播来估计梯度。

一个模型更新可以被编码为两个标量

ZOO基于一个随机扰动和一个损失值来估计梯度

$$\hat{\mathbf{g}}_{i,t}^r \triangleq \frac{\mathcal{L}(\mathbf{w}_{i,t}^r + \epsilon \mathbf{z}; \mathbf{x}) - \mathcal{L}(\mathbf{w}_{i,t}^r - \epsilon \mathbf{z}; \mathbf{x})}{2\epsilon}$$

标量梯度 (一个浮点数)

一个随机扰动 $\xrightarrow{\text{编码为}}$ 一个随机数 (一个整数)

$$\mathbf{z} \approx \mathbf{z}\mathbf{z}^\top \hat{\mathbf{g}}_{i,t}^r$$

*两点估计

- $\hat{\mathbf{g}}_{i,t}^r$: 客户端i在第r轮第t步, 通过ZOO估计出的模型梯度;
- $\mathcal{L}(\cdot)$: 损失函数;
- $\mathbf{w}_{i,t}^r$: 客户端i在第r轮第t步的本地模型参数;
- ϵ : 扰动尺度, 控制梯度估计精度与稳定性的常数;
- $\mathbf{z}$: 随机扰动向量, 服从 $\mathcal{N}(0, I_d)$;
- I_d : d 维单位矩阵;
- d : 模型参数维度。

Client 1

Client i

$\langle seed_1, grad_1 \rangle$

$\langle seed_2, grad_2 \rangle$

$\langle seed_3, grad_3 \rangle$

paired seeds and scalar gradients

图3: ZOO的每一步都可以通过生成扰动的随机种子和基于该种子的标量梯度复现

Number of Rounds	NVIDIA V100 (Hours)	Apple M2 (Hours)
1	~0.1	~1
6	~0.5	~10
11	~1	~20
16	~2	~40
21	~3	~60
26	~4	~70
31	~5	~75
36	~6	~78
40	~10	~80

图4: 计算最新全局模型所需时间与总步数

[1] Yurii Nesterov and Vladimir Spokoiny. 2017. Random gradient-free minimization of convex functions. Foundations of Computational Mathematics, Vol. 17. 527–566.(JCR-Q1)

Federated Full-Parameter Tuning of Billion-Sized Language Models with Communication Cost under 18 Kilobytes




图5: FedKSeed概述

- 种子概率(Seed Probabilities)①:
- 候选种子集(Candidate Seeds)②:
- 标量梯度累加器(Scalar Gradient Accumulator)③:
- 标量梯度历史(Scalar Gradient History)④:

Federated Full-Parameter Tuning of Billion-Sized Language Models with Communication Cost under 18 Kilobytes

Algorithm 1: The processes of **FedKSeed**, where the underlined components and processes are only required by the enhanced version of it that samples seeds during local training with non-uniform probabilities, i.e., **FedKSeed-Pro**.

Input: $N, K, \mathbf{w}^0, \eta, \{c_1, \dots, c_N\}, T$ and τ .

Output: The global model $\mathbf{w}^T$ that has been fine-tuned for T rounds.

```

1 Server Executes: initialize  $K$  candidate seeds  $\mathbb{S}$ , scalar gradient accumulator  $\mathcal{A}$ , and their probabilities  $\mathbf{p}$ .
2 for each round  $r = 1, 2, \dots, T$  do
3   for each client  $i \in \text{activate clients } \mathbb{C}$  in parallel do
4      $\mathbb{H}_i \leftarrow \text{ClientTraining}(\mathbb{S}, \mathcal{A}, \underline{\mathbf{p}}, i)$  // ① 服务器下发"候选种子集"和"标量梯度累加器"
5     for  $(s_j, \hat{\varrho}_j) \in \mathbb{H}_i$  do
6        $a_j = a_j + c_i \cdot \hat{\varrho}_j$  // ⑤ 服务器更新"标量梯度累加器"
7     compute the seed importance and then the probability  $\mathbf{p}$  as Equation (13) // ⑥ 计算种子的重要性与概率
8 return the fine-tuned global model  $\mathbf{w}^T$ , which is calculated with  $\mathbf{w}^0$  as the initial point based on  $\mathcal{A}$ , as Equation (4)

9 Function ClientTraining( $\mathbb{S}, \mathcal{A}, \underline{\mathbf{p}}, i$ ):
10   calculate the latest global model with  $\mathbf{w}^0$  as the initial point based on  $\mathcal{A}$ , as Equation (4) // ② 客户端基于"候选种子集"和"标量梯度累加器"计算最新模型
11   for each local step  $t = 1, 2, \dots, \tau$  do
12     sample a data instance  $\mathbf{x}$  from local dataset  $\mathcal{D}_i$ , a seed  $s_j$  from  $\mathbb{S}$  based on  $\mathbf{p}$ , then generate a perturbation  $\mathbf{z}_j$ 
13     with  $s_j$  as the random seed // ③-1 从"候选种子集"中选一个种子生成扰动向量, 计算该步的标量梯度
14      $\hat{\varrho}_j = \frac{\mathcal{L}(\mathbf{w} + \epsilon \mathbf{z}_j; \mathbf{x}) - \mathcal{L}(\mathbf{w} - \epsilon \mathbf{z}_j; \mathbf{x})}{2\epsilon}$ 
15      $\mathbf{w}_{t+1} = \text{UpdateModel}(\mathbf{w}_t, s_j, \hat{\varrho}_j)$  // ③-2 用种子 $s_i$ 和标量梯度 $\hat{\varrho}_i$ 更新本地模型 $\mathbf{w}$ 
16     stage  $(s_j, \hat{\varrho}_j)$  into  $\mathbb{H}_i$  // ④-1 客户端将自己积累的"标量梯度历史"发送给服务器
17   return  $\mathbb{H}_i$  to the server

17 Function UpdateModel( $\mathbf{w}, s, \hat{\varrho}$ ):
18   sample perturbation  $\mathbf{z} \in \mathbb{R}^d$  with random seed  $s$ 
19   return  $\mathbf{w} - \eta \cdot \hat{\varrho} \cdot \mathbf{z}$ 

```


种子再利用的理论支持(Theoretical support for seed reuse):

质疑：标准的ZOO假设每次更新都从无限的随机分布中采样一个新的扰动方向，**如果将随机种子限制在一个有限集合K中，是否会导致训练无法收敛？**

FedZO[2]：使用单点估计器(One-point estimator)，依赖多组独立同分布(iid)的扰动与小批量样本计算梯度，是传统零阶优化(ZOO)在联邦场景下的实现；

$$\hat{\mathbf{g}}_{i,t}^r = \frac{1}{b_1 b_2} \sum_{b=1}^{b_1} \sum_{j=1}^{b_2} \frac{[\mathcal{L}(\mathbf{w}_{i,t}^r + \epsilon \mathbf{z}_j; \mathbf{x}_b) - \mathcal{L}(\mathbf{w}_{i,t}^r; \mathbf{x}_b)]}{\epsilon} \mathbf{z}_j \quad (4)$$

*单点估计

FedMeZO：是FedZO的变体，将FedZO的梯度估计器替换为MeZO[3]的单样本两点估计器——仅用单个样本、两组相反的扰动计算梯度，更适配终端设备的低内存需求。

$$\hat{\mathbf{g}}_{i,t}^r \triangleq \frac{\mathcal{L}(\mathbf{w}_{i,t}^r + \epsilon \mathbf{z}; \mathbf{x}) - \mathcal{L}(\mathbf{w}_{i,t}^r - \epsilon \mathbf{z}; \mathbf{x})}{2\epsilon} \mathbf{z} \quad (3)$$

*两点估计

两点估计得到的梯度与单点估计在两组扰动下得到的两个均值类似，推导如下：

$$\begin{aligned} & \mathbf{z} [\mathcal{L}(\mathbf{w} + \epsilon \mathbf{z}; \mathbf{x}) - \mathcal{L}(\mathbf{w}; \mathbf{x})] + (-\mathbf{z}) [\mathcal{L}(\mathbf{w} - \epsilon \mathbf{z}; \mathbf{x}) - \mathcal{L}(\mathbf{w}; \mathbf{x})] \\ &= \mathbf{z} [\mathcal{L}(\mathbf{w} + \epsilon \mathbf{z}; \mathbf{x}) - \mathcal{L}(\mathbf{w} - \epsilon \mathbf{z}; \mathbf{x})]. \end{aligned}$$




图6：LLaMA-3B使用FedZO与FedMeZO全参数微调收敛曲线(NI)

[2] Wenzhi Fang, Ziyi Yu, Yuning Jiang, Yuanming Shi, Colin N Jones, and Yong Zhou. 2022. Communication-efficient stochastic zeroth-order optimization for federated learning. IEEE Transactions on Signal Processing, Vol. 70. 5058–5073.(CCF-B)

[3] Zhenqing Ling, Daoyuan Chen, Liuyi Yao, Yaliang Li, and Ying Shen. 2024. On the Convergence of Zeroth-Order Federated Tuning for Large Language Models. In Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '24). 1827–1838.(CCF-A)

种子再利用的理论支持(Theoretical support for seed reuse):

在标准的ZOO中, 随机扰动的均值为0, 但给定从正态分布 $\mathcal{N}(0,1)$ 中随机采样得到的集合 $Z' = \{Z'_1, Z'_2, \dots, Z'_k\}$, 从中进行 Γ 次采样, 其采样得到的变量 $Z_1, Z_2, \dots, Z_\Gamma$ 独立同分布, 令 $\bar{S}_\Gamma = \sum_{i=1}^\Gamma Z_i$ 则满足:

$$\Pr[|\bar{S}_\Gamma - 0| \geq \varepsilon] \leq \frac{4}{K\varepsilon^2} + 2 \exp\left(-\frac{\Gamma\varepsilon^2}{2[\max(Z') - \min(Z')]^2}\right) \quad (5)$$

由上式, 基于种子得到的随机扰动 z 的均值与0之间存在一个**均值偏移** ε , 而在本文的微调任务中 K 的取值为数千级别, 而 Γ 每轮会以万为单位增长。

对于服从 d 维标准正态分布($\mathcal{N}(0, I_d)$)的 z 由有限种子两点估计器得到的梯度 $\hat{g}_1$ 与无限种子的两点估计器得到的梯度 $\hat{g}_2$ 满足:

$$\|\hat{g}_1 - \hat{g}_0\| \leq 2L \|z\| \|\vec{\varepsilon}\| + L \|\vec{\varepsilon}\|^2 \quad (6)$$

二者的误差从直观来看会很小, 有原因如下:

1. 两点梯度估计器在方向上具有对称性;
2. 该误差被 ε (非常小)所界定。

考虑以下两点:

1. **两点梯度估计器不劣于单点估计器**(图6);
2. **梯度估计误差的极小性**(图7);

有结论: **FedKSeed在收敛性上与FedZO并无显著差异。**





图7: 用 K 个候选随机种子随机采样得到的扰动的均值



(a) DataJuicer-1.3B

(b) LLaMA-3B

图8: FedKSeed和FedZo全参数微调收敛(NI)


K的选择(Selection of K):

K的选择用内在维度理论[4], 将寻找w转换为寻找系数向量 $G \in \mathbb{R}^K$
待优化变量是G而非直接优化模型参数


$$\min_{G \in \mathbb{R}^K} \sum_{i=1}^N c_i \cdot \mathbb{E}_{\mathbf{x} \sim \mathcal{D}_i} \left[\mathcal{L} \left(\underbrace{\mathbf{w}^0}_{\text{模型初始参数}} + \underbrace{[\mathbf{z}_1, \dots, \mathbf{z}_K]}_{\text{种子扰动矩阵}} G ; \mathbf{x} \right) \right] \quad (7)$$

The difference from Equation (1)

- G : 需要优化的变量(向量), 代表了在 K 维随机子空间中的系数, 其中第 j 个元素对应于 s_j 的扰动的所有标量梯度的和。



(a) DataJucer-1.3B Natural Instructions (c) DataJucer-1.3B Dolly-15K ($\alpha=0.5$) (e) DataJucer-1.3B Dolly-15K ($\alpha=5.0$)



(b) LLaMA-3B Natural Instructions (d) LLaMA-3B Dolly-15K ($\alpha=0.5$) (f) LLaMA-3B Dolly-15K ($\alpha=5.0$)

图9: FedKSeed和FedKSeed-Pro在不同候选种子数量下的Rouge-L指标性能

选择K的关键原则:

1. 种子不足(Seed Insufficiency)
存在一个下限阈值 K (大约在1024), 当 $K < \underline{K}$ 时, K 越小, 模型精度越差;
2. 种子过量(Seed Excessiveness)
存在一个上限阈值 $\bar{K}$ (大约在4096), 当 $K \geq \bar{K}$ 时, 继续增加 K 不会提高精度, 甚至可能导致精度下降。

[4] Armen Aghajanyan, Sonal Gupta, and Luke Zettlemoyer. 2021. Intrinsic Dimensionality Explains the Effectiveness of Language Model Fine-Tuning. In Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 7319–7328. (CCF-A)

采用非均匀概率的种子采样(Sampling Seeds with Non-uniform Probabilities):

并不是所有的随机扰动(种子)都同等重要, FedKSeed-pro增加更有用的种子的采样概率, 从而用更少的种子(更小的K)达到更好的效果。

算法步骤:

1. 计算平均幅度(ψ_j):

服务器收集所有客户端回传的关于种子 s_j 的标量梯度, 计算其绝对值的平均值;

$$\psi_j = \frac{1}{|\mathcal{G}_j|} \sum_{\hat{g} \in \mathcal{G}_j} |\hat{g}| \quad (8)$$

2. 归一化(ψ_j^{norm}):

为了防止差异过大, 对K个种子的重要性分数 ψ 进行Min-Max归一化;

3. 计算采样概率(p_j):

使用Softmax函数将重要性分数转换为概率分布;

$$p_j = \frac{\exp(\psi_j^{norm})}{\sum_{k=1}^K \exp(\psi_k^{norm})} \quad (9)$$

4. 下发概率:

每一轮通信, 不仅下发种子列表, 还下发对应的概率表 $\{p_1, \dots, p_K\}$, 客户端本地训练时按照概率表来偏心采样种子。

实验方法设计:

基线方法(Baselines):

➤ PEFT

- FedPTuning (2024,KDD)
- FedPrompt (2024,KDD)
- FedIT (2024,ICASSP)
- FedIT-SGD

➤ Full-prameter References

- FedAvg (2017,AISTATS)
- FedZO (2022,IEEE TSP)
- FedMeZO(FedAvg+MeZO) (2024,KDD)

联邦设置:

➤ 客户端参与度: 每轮随机采样5%客户端;

➤ 通信轮数:

- NI数据集: 40轮
- Dolly-15K数据集: 60轮

➤ 本地训练步数:

- BP基准: 本地训练1个Epoch
- ZOO: 本地训练200Steps

➤ Batch Size: 1

➤ FedKSeed随机种子数量:

- FedKSeed: K=4096
- FedKSeedPro:
 - DataJuicer-1.3B: 1024
 - LLaMA-3B: 2048

➤ 评估指标: Rouge-L

预训练模型:

- DataJuicer-1.3B
- LLaMA-3B

实验环境:

- NVIDIA RTX3090
- NVIDIA A100

数据集设置:

➤ Natural Instruction(NI)

- **类型:** 按照任务划分数据, 不同客户端有不同任务;
- **设置:** 738个训练任务, **每个任务分配给一个唯一的客户端**, 119个测试任务用于全局评估。

➤ Dolly-15K

- **类型:** 标签分布偏斜;
- **设置:** 最后一个任务用于全局评估, 其余数据分配给200个客户端, 使用迪利克雷(Dirichlet)分布, 设置 $\alpha=\{0.5,5.0\}$ 划分数据, α 越小表示数据异质性越高。

Federated Full-Parameter Tuning of Billion-Sized Language Models with Communication Cost under 18 Kilobytes


表1: Rouge-L指标对比(标为灰色部分通信成本过高, 实际场景不可用)

Approach	Natural Instructions		Dolly-15K ($\alpha = 0.5$)		Dolly-15K ($\alpha = 5.0$)	
	DataJuicer-1.3B	LLaMA-3B	DataJuicer-1.3B	LLaMA-3B	DataJuicer-1.3B	LLaMA-3B
FedAvg	22.08 $\pm$ 1.52	27.88 $\pm$ 0.75	32.30 $\pm$ 1.23	34.27 $\pm$ 0.45	33.38 $\pm$ 1.43	33.95 $\pm$ 0.79
FedZO	21.74 $\pm$ 1.91	29.46 $\pm$ 0.38	32.91 $\pm$ 0.67	36.34 $\pm$ 0.39	33.28 $\pm$ 0.42	36.72 $\pm$ 0.18
FedMeZO	21.71 $\pm$ 1.26	30.18 $\pm$ 0.69	33.32 $\pm$ 0.14	35.66 $\pm$ 1.06	33.07 $\pm$ 0.47	36.21 $\pm$ 0.15
FedPTuning	19.61 $\pm$ 2.71	25.41 $\pm$ 1.14	23.98 $\pm$ 3.23	30.30 $\pm$ 1.16	25.33 $\pm$ 2.48	29.08 $\pm$ 1.33
FedPrompt	6.04 $\pm$ 0.12	8.95 $\pm$ 2.47	32.73 $\pm$ 0.87	24.50 $\pm$ 4.78	32.51 $\pm$ 1.31	23.94 $\pm$ 4.15
FedIT-SGD	19.40 $\pm$ 1.83	28.14 $\pm$ 0.85	27.23 $\pm$ 0.68	29.28 $\pm$ 0.50	27.28 $\pm$ 1.35	29.19 $\pm$ 0.89
FedIT	22.30 $\pm$ 0.42	28.13 $\pm$ 0.50	30.80 $\pm$ 0.98	33.23 $\pm$ 1.51	30.97 $\pm$ 0.43	33.68 $\pm$ 1.07
FedKSeed	22.33 $\pm$ 1.72	29.77 $\pm$ 0.75	32.90 $\pm$ 0.37	35.64 $\pm$ 0.83	33.12 $\pm$ 0.31	35.93 $\pm$ 1.35
FedKSeed-Pro	23.50 $\pm$ 1.35	30.19 $\pm$ 1.10	33.18 $\pm$ 0.68	36.29 $\pm$ 0.63	33.00 $\pm$ 0.34	35.95 $\pm$ 1.41


- 召回率: $R_{LCS} = \frac{LCS(X,Y)}{m}$, 其中 m 为参考文本 X 的长度, $LCS(X,Y)$ 为 X 与生成文本 Y 的最长公共子序列长度。
- 精确率: $P_{LCS} = \frac{LCS(X,Y)}{n}$, 其中 n 为生成文本 Y 的长度。
- F1分数: $ROUGE - L = \frac{(1+\beta^2) \cdot R_{LCS} \cdot P_{LCS}}{R_{LCS} + \beta^2 \cdot P_{LCS}}$, β 为权重参数 (通常取1, 平衡召回与精确; $\beta > 1$ 侧重召回, $\beta < 1$ 侧重精确)。

表2: 每轮通信开销与巅峰GPU内存占用

Approach	DataJuicer-1.3B		LLaMA-3B	
	Commun.	Memory	Commun.	Memory
FedAvg	5.01 GB	17.8 GB	12.76 GB	39.1 GB
FedZO	5.01 GB	3.4 GB	12.76 GB	7.6 GB
FedMeZO	5.01 GB	3.5 GB	12.76 GB	7.8 GB
FedPTuning	96.36 MB	11.9 GB	234.9 MB	16.3 GB
FedPrompt	320.0 KB	11.8 GB	500.0 KB	19.0 GB
FedIT-SGD	12.00 MB	12.4 GB	20.31 MB	18.2 GB
FedIT	12.00 MB	12.4 GB	20.31 MB	18.3 GB
FedKSeed	17,988 B	3.5 GB	17,988 B	7.8 GB
FedKSeed-Pro	9,796 B	3.5 GB	17,988 B	7.8 GB



(a) DataJuicer-1.3B on Natural Instructions



(b) LLaMA-3B on Natural Instructions

图10: PEFT方法每步训练时间(NVIDIA V100测量)和可训练参数量

Federated Full-Parameter Tuning of Billion-Sized Language Models with Communication Cost under 18 Kilobytes




图9: FedKSeed和FedKSeed-Pro在不同候选种子数量下的Rouge-L指标性能




图11: FedKSeed计算最新模型(LLaMA-3B)的耗时




图12: FedKSeed-Pro在Dolly-15K($\alpha=0.5$)不同 η 与 ϵ 组合


FedKSeed-Pro 只需更少的种子即可达到与
FedKSeed 相同的精度

候选种子越少最新模型计算耗时越少

需要选取合适的学习率(η)与扰动尺度(ϵ)

学习率 η

扰动尺度 ϵ



(a)客户端总数的影响(NI)

(b)客户端参与比率的影响(Dolly-15K $\alpha=0.5$)

图13：基于LLaMA-3B在各类FL场景下的性能表现，FedKSeed的K=4096，FedKSeed-Pro的K=2048

- a) 得益于更多有价值的数据，四种方法与基线模型的精度均有所提升——这进一步印证了联邦微调的重要性，因为它能够利用更广泛的数据源；
- b) 随着更多客户端参与每一轮联邦学习，这些方法的精度会逐步提升并趋于稳定；

FedKSeed与FedKSeed-Pro在各类场景中均优于Baseline，进一步证明了其优越性。




图5: FedKSeed概述

总结:

- 1. 本文聚焦于“**联邦学习场景下大语言模型(Fed-LLMs)全参数微调的高通信/内存成本**”这一核心痛点，提出了基于零阶优化(ZOO)种子复用机制的FedKSeed，**首次实现了十亿级LLMs在终端设备上可承载的联邦全参数微调**；
- 2. 基于FedKSeed，本文受“**扰动对应的标量梯度是真实梯度的方向导数**”这一特性启发，提出了一种**量化种子重要性并为其分配差异化采样概率**的策略FedKSeed-Pro。该策略减少了所需种子的数量，从而加快了最新模型的获取速度也实现了更高的精度；
- 3. 在真实数据上的大量实验表明，该方法在**精度、通信成本和内存**占用这三方面，均**超越了专为LLMs微调设计的联邦学习基线方法**。



汇报结束，感谢！